

Corrigé du TD 6

Exercice 1. (pas de corrigé) Soit $(X_n, n \geq 1)$, une suite de variables aléatoires indépendantes, de loi normale $N(\theta, \theta)$, avec $\theta > 0$. L'objectif de cet exercice est de présenter deux tests pour déterminer si pour une valeur déterminée $\theta_0 > 0$, on a $\theta = \theta_0$ (hypothèse H_0) ou $\theta > \theta_0$ (hypothèse H_1). On note

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad V_n = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{1}{n-1} \sum_{i=1}^n X_i^2 - \frac{n}{n-1} \bar{X}_n^2$$

1. Déterminer $\hat{\theta}_n$, l'estimateur du maximum de vraisemblance de θ . Montrer directement qu'il est convergent, asymptotiquement normal et donner sa variance asymptotique. Est-il asymptotiquement efficace ?

2. Construire un test asymptotique convergent à l'aide de l'estimateur du maximum de vraisemblance. On considère la classe des estimateurs T_n^λ de la forme $T_n^\lambda = \lambda \bar{X}_n + (1 - \lambda) V_n$.

3. Montrer que la suite d'estimateurs $(T_n^\lambda, n \geq 2)$ est convergente, sans biais. Donner la variance de T_n^λ .

Exercice 2. L'information dans une direction de l'espace prise par un radar de surveillance aérienne se présente sous la forme d'un n-échantillon $X = (X_1, \dots, X_n)$ de variables aléatoires indépendantes de même loi gaussienne de moyenne θ , paramètre inconnu, et de variance σ^2 connu. On notera $f(x, \theta), x \in \mathbb{R}^n$ la densité du vecteur aléatoire.

En l'absence de tout Objet Volant (Hypothèse H_0) $\theta = \theta_0 \in \mathbb{R}^+$, sinon (Hypothèse H_1), $\theta = \theta_1$, avec $\theta_1 > \theta_0$.

1. En utilisant Neyman-Pearson, construire un test de l'hypothèse $\theta = \theta_0$ contre l'hypothèse $\theta = \theta_1$ de niveau α .

On calcule d'abord le rapport de vraisemblance :

$$\frac{L(x, \theta_1)}{L(x, \theta_0)} = \exp \left(- \sum_{i=1}^n \frac{(x_i - \theta_1)^2 - (x_i - \theta_0)^2}{2\sigma^2} \right) = \exp \left(M \frac{\sqrt{n}(\bar{x}_n - \theta_0)}{\sigma} - \frac{1}{2} M^2 \right)$$

avec $M = \frac{\sqrt{n}(\theta_1 - \theta_0)}{\sigma}$. La région critique optimale est donc de la forme :

$$W_\alpha = \left\{ (x_1, \dots, x_n), \frac{\sqrt{n}(\bar{x}_n - \theta_0)}{\sigma} > k_\alpha \right\}$$

On obtient ainsi la statistique de test $\frac{\sqrt{n}(\bar{X}_n - \theta_0)}{\sigma}$ qui suit, sous H_0 , la loi gaussienne $\mathcal{N}(0, 1)$. On doit donc choisir k_α tel que $\alpha = P_{\theta_0}(W_\alpha)$. On obtient donc $k_\alpha = \phi^{-1}(1 - \alpha)$ avec ϕ la fonction de répartition de la gaussienne centrée réduite.

Remarque : La région critique est indépendante de la valeur de θ_1 (avec $\theta_1 > \theta_0$). Ce test est donc aussi un test de niveau α pour tester $\{\theta = \theta_0\}$ contre $\{\theta > \theta_0\}$.

2. Quelle est la plus petite valeur de n permettant de construire un test de niveau $\alpha, \alpha \in [0, 1]$ et d'erreur de deuxième espèce inférieure ou égale à $\beta, \beta \in [0, 1]$, avec $\alpha < \beta$?

Sous H_1 , i.e. $\theta = \theta_1$, $\frac{\sqrt{n}(\bar{X}_n - \theta_0)}{\sigma} - M$ suit la loi $\mathcal{N}(0, 1)$. L'erreur de deuxième espèce est donnée par

$$\begin{aligned} P_{\theta_1}(\bar{W}_\alpha) &= P_{\theta_1} \left(\frac{\sqrt{n}(\bar{X}_n - \theta_0)}{\sigma} < k_\alpha \right) \\ &= P_{\theta_1} \left(\frac{\sqrt{n}(\bar{X}_n - \theta_0)}{\sigma} - M < k_\alpha - M \right) \leq \beta \end{aligned}$$

On veut que l'erreur de deuxième espèce $\leq \beta$. Donc,

$$\begin{aligned} P_{\theta_1} \left(\frac{\sqrt{n}(\bar{X}_n - \theta_0)}{\sigma} - M < k_\alpha - M \right) &\leq \beta \\ \text{d'où } k_\alpha - M &\leq \phi^{-1}(\beta) \end{aligned}$$

Autrement dit :

$$\begin{aligned} \frac{\sqrt{n}(\theta_1 - \theta_0)}{\sigma} &> k_\alpha - \phi^{-1}(\beta) \\ n &\geq \sigma^2 \frac{[\phi^{-1}(1 - \alpha) - \phi^{-1}(\beta)]^2}{(\theta_1 - \theta_0)^2} \end{aligned}$$

3. Supposons maintenant qu'en presence d'objet volant l'information fournie par le radar est un n-échantillon $X = (X_1, \dots, X_n)$ de variables aléatoires indépendantes de même loi gaussienne de moyenne $\theta \neq \theta_0$, $\theta \in \mathbb{R}$ et de variance σ^2 . Peut-on construire un test de l'hypothèse $\theta = \theta_0$ contre l'hypothèse $\theta \neq \theta_0$ de niveau α donné uniformément plus puissant ?

C'est un test bilatéral, la même méthode s'applique ! On a donc la même statistique de test mais la région de rejet est de la forme :

$$W_\alpha = \left\{ (x_1, \dots, x_n), k_{(\alpha,1)} < \frac{\sqrt{n}(\bar{x}_n - \theta_0)}{\sigma} < k_{(\alpha,2)} \right\}$$

Exercice 3. Une agence de voyage souhaite cibler sa clientèle. Elle sait que les coordonnées du lieu de vie d'un client (X, Y) rapportées au lieu de naissance $(0, 0)$ sont une information significative pour connaître le goût de ce client. Elle distingue :

- La population 1 (Hypothèse H_0) dont la loi de répartition a pour densité :

$$p_1(x, y) = \frac{1}{2\pi} e^{-\frac{x^2 + y^2}{2}}$$

- La population 2 (Hypothèse H_1) dont la loi de répartition a pour densité :

$$p_2(x, y) = \frac{1}{16} \mathbf{1}_{[-2,2]}(x) \mathbf{1}_{[-2,2]}(y)$$

L'agence souhaite tester l'hypothèse qu'un nouveau client vivant en (x, y) appartient à la population 1 plutôt qu'à la population 2.

1. Proposer un test de niveau inférieur à $\alpha = 5\%$ et de puissance maximale, construit à partir du rapport de vraisemblance.

Cet exemple rentre dans le cadre du Lemme de Neyman-Pearson. On définit la région critique du test :

$$A_\alpha = \left\{ (x, y) \in \mathbb{R}^2; \frac{p_2(x, y)}{p_1(x, y)} > ka \right\}.$$

On obtient

$$A_\alpha = \{(x, y) \in \mathbb{R}^2 \cap ([-2; 2] \times [-2; 2]); x^2 + y^2 > ka\}.$$

Sous H_0 , $X^2 + Y^2$ suit une loi du χ^2_2 (à 2 degrés de liberté). On a $5\% = P(\chi^2_2) = 5.99$. Soit α tel que $K_\alpha = 5.99$. On en déduit donc que $P_{H_0}(A_\alpha) = \alpha = 5\%$.

2. Donner une statistique de test et caractériser graphiquement la région critique dans \mathbb{R}^2 .

Une statistique de test est $X^2 + Y^2$. La région critique est l'intersection de l'extérieur du cercle de rayon $\sqrt{5.99}$ avec le carré $[-2; 2] \times [-2; 2]$.

Exercice 4. Soit X_1, \dots, X_n un n-échantillon de loi exponentielle de paramètre $\frac{1}{\theta} > 0$.

1. Construire le test de niveau α $H_0 = \{\theta = \theta_0\}$ contre $H_1 = \{\theta > \theta_0\}$.

La méthode à utiliser pour construire un test unilatéral est la même que pour un test simple, à savoir la méthode de Neyman-Pearson. Soit un certain $\theta' > \theta$. On étudie le rapport de vraisemblance :

$$\frac{p_n(x_1, \dots, x_n, \theta')}{p_n(x_1, \dots, x_n, \theta_0)} = \left(\frac{\theta_0}{\theta'}\right)^n \exp \left\{ - \left(\frac{1}{\theta'} - \frac{1}{\theta_0} \right) \sum_{i=1}^n x_i \right\}$$

Appliquant le Théorème de Neyman-Pearson, on obtient que la région de rejet optimale de niveau α , W_α , est de la forme :

$$\begin{aligned} W_\alpha &= \left\{ (x_1, \dots, x_n); \frac{p_n(x_1, \dots, x_n, \theta')}{p_n(x_1, \dots, x_n, \theta_0)} > k_\alpha \right\} \\ &= \left\{ (x_1, \dots, x_n); \sum_{i=1}^n x_i > C_\alpha \right\} \end{aligned}$$

où $\alpha = P_{\theta_0}(W_\alpha)$. On déduit également la statistique de test $\sum_{i=1}^n X_i$ qui suit, sous H_0 , la loi gamma

$\Gamma(n, \frac{1}{\theta_0})$. Donc, $\frac{2}{\theta_0} \sum_{i=1}^n X_i$ suit la loi Gamma $\Gamma(n, \frac{1}{2})$, i.e. la loi du χ^2 à $2n$ degrés de liberté (toujours sous l'hypothèse nulle). Donc, on peut déterminer C_α :

$$\alpha = P_{\theta_0} \left(W_\alpha \right) = P_{\theta_0} \left(\sum_{i=1}^n X_i > C_\alpha \right) = P_{\theta_0} \left(\frac{2}{\theta_0} \sum_{i=1}^n X_i > \frac{2}{\theta_0} C_\alpha \right)$$

Donc, $\frac{2}{\theta_0} C_\alpha = F_{\chi^2_{2n}}^{-1}(1 - \alpha)$. On obtient donc la région critique :

$$W_\alpha = \left\{ (x_1, \dots, x_n); \sum_{i=1}^n x_i > \frac{\theta_0}{2} F_{\chi^2_{2n}}^{-1}(1 - \alpha) \right\}$$

2. Construire le test de niveau α , $H_0 = \{\theta = \theta_0\}$ contre $H_1 = \{\theta \neq \theta_0\}$.

La région critique optimale du test bilatéral de niveau α est donnée par :

$$W_\alpha = \left\{ (x_1, \dots, x_n); \sum_{i=1}^n x_i < k_1, \sum_{i=1}^n x_i > k_2 \right\}$$

avec k_1 et k_2 tels que $\alpha = P_{\theta_0}(W_\alpha)$.

$$\begin{aligned} 1 - \alpha &= P_{\theta_0} \left(k_1 < \sum_{i=1}^n X_i < k_2 \right) \\ &= P_{\theta_0} \left(\frac{2}{\theta_0} k_1 < \frac{2}{\theta_0} \sum_{i=1}^n X_i < \frac{2}{\theta_0} k_2 \right) \end{aligned}$$

Sous h_0 , $\frac{2}{\theta_0} \sum_{i=1}^n X_i$ suit la loi χ_{2n}^2 , on choisit donc $\frac{2}{\theta_0} k_1 = F_{\chi_{2n}^2}^{-1}(\alpha_1)$ et $\frac{2}{\theta_0} k_2 = F_{\chi_{2n}^2}^{-1}(1 - \alpha_2)$, avec $\alpha_1 + \alpha_2 = \alpha$. Un choix classique consiste à prendre $\alpha_1 = \alpha_2 = \frac{\alpha}{2}$.

(a). Le rapport de vrais.
$$\frac{L(\lambda_1, x_1, \dots, x_n)}{L(\lambda_0, x_1, \dots, x_n)} = e^{n(\lambda_0 - \lambda_1) \left(\frac{\lambda_1}{\lambda_0}\right)^{\hat{\lambda}}};$$

où $\hat{\lambda} = \bar{X}$.

C'est une fonction croissante de $\hat{\lambda}$. Donc, d'après le théorème de N-P, la RC optimale au niveau α^* est de la forme $W : \hat{\lambda} > A$ pour une constante A vérifiant

$$P_{\lambda_0}(\hat{\lambda} > A) = \alpha^*.$$

(b) D'après le TLC, on a approximativement pour n grand et sous l'hypothèse H_0 :

$$\hat{\lambda} \sim \mathcal{N}(\lambda_0, \lambda_0/n)$$

On en déduit :

$$A \approx \lambda_0 + u_{1-\alpha^*} \sqrt{\frac{\lambda_0}{n}}$$

A.N. : $A \approx 1.87$, $\hat{\lambda} = 1.8$, donc on conserve l'hypothèse H_0 .

(c) On a :

$$\pi = P_{\lambda_1}(\hat{\lambda} > A) \approx 1 - \phi\left(\frac{A - \lambda_1}{\sqrt{\lambda_1/n}}\right)$$

A.N. : $\pi \approx 0.69$.

(d) Soit le problème de test :

$$\begin{aligned} H_0 : & \lambda = \lambda_0 \\ H_1 : & \lambda = \lambda_1 \end{aligned}$$

avec $\lambda_1 > \lambda_0$. La RC optimale pour ce problème a été trouvée précédemment, elle ne dépend pas de λ_1 . Par conséquent, le test précédent est UPP pour le problème de test H_0 contre H_1 .

D'après les résultats numériques trouvés précédemment, il n'y a donc pas lieu de remettre en cause l'affirmation du Ministère de l'Intérieur (au niveau de signification de 5 %).